

# Sistem Rekomendasi menggunakan Algoritma Firefly

Muhammad Zaki Abdillah<sup>1,a,\*</sup>, Halilah Roja Nasywa<sup>2,b,\*</sup>, Veni Zahara Kartika<sup>3,c,\*</sup>, Elsyah Sapyrah<sup>4,d,\*</sup>,  
Muhammad Kaisar Firdaus<sup>5,e,\*</sup>

<sup>1</sup>121450008, <sup>2</sup>121450046, <sup>3</sup>121450075, <sup>4</sup>121450096, <sup>5</sup>121450135

<sup>a</sup>[muhammad.121450008@student.itera.ac.id](mailto:muhammad.121450008@student.itera.ac.id), <sup>b</sup>[halilah.121450046@student.itera.ac.id](mailto:halilah.121450046@student.itera.ac.id),  
<sup>c</sup>[veni.121450075@student.itera.ac.id](mailto:veni.121450075@student.itera.ac.id), <sup>d</sup>[elsyah.121450096@student.itera.ac.id](mailto:elsyah.121450096@student.itera.ac.id),  
<sup>e</sup>[muhammad.121450135@student.itera.ac.id](mailto:muhammad.121450135@student.itera.ac.id)

<sup>\*</sup>Sains Data, Fakultas Sains, Institut Teknologi Sumatera

---

## Abstrak

Pada era digital saat ini, penyajian informasi yang relevan dan sesuai dengan kebutuhan pengguna menjadi suatu hal yang sangat penting. Banyak variabel yang harus dipertimbangkan untuk memberikan informasi yang tepat, yang menjadikannya sebuah permasalahan urgensi yang perlu diselesaikan. Dalam konteks dunia digital film, memberikan rekomendasi film yang sesuai dengan preferensi pengguna merupakan sebuah tantangan tersendiri. Solusi yang tepat untuk mengatasi masalah ini adalah dengan menerapkan Sistem Rekomendasi. Penelitian yang dilakukan menggunakan teknik rekomendasi Collaborative Filtering dengan metode Pearson Correlation dan algoritma Firefly dalam menentukan rekomendasi film yang sesuai dengan pengguna. Collaborative Filtering adalah sebuah teknik yang memanfaatkan pola preferensi pengguna lain yang memiliki kesamaan dengan pengguna tertentu untuk memberikan rekomendasi. Metode Pearson Correlation digunakan untuk menghitung nilai kemiripan antar pengguna berdasarkan rating atau penilaian yang diberikan terhadap suatu film. Semakin tinggi nilai kemiripan antara dua pengguna, semakin besar kemungkinan mereka memiliki preferensi film yang serupa. Namun, teknik Collaborative Filtering memiliki kelemahan, yaitu munculnya masalah sparsity atau kekosongan data. Ini terjadi ketika pengguna hanya memberikan rating untuk sebagian kecil film saja, sehingga terdapat banyak data yang kosong atau tidak ada nilai ratingnya. Untuk mengatasi kelemahan ini, peneliti melakukan penghapusan terhadap data yang kosong atau tidak memiliki nilai rating. Selanjutnya, peneliti menggunakan algoritma Firefly untuk menentukan film yang paling sesuai dengan preferensi pengguna. Algoritma Firefly adalah sebuah algoritma optimasi yang terinspirasi dari perilaku kunang-kunang dalam mencari pasangan dengan intensitas cahaya terbesar. Dalam konteks ini, algoritma Firefly digunakan untuk mencari kombinasi film yang paling optimal berdasarkan nilai kemiripan antar pengguna yang dihitung menggunakan metode Pearson Correlation. Hasil dari penelitian ini menunjukkan bahwa sistem rekomendasi yang dikembangkan memiliki Mean Absolute Error (MAE) sebesar 2,40 dan Mean Squared Error (MSE) sebesar 5,76. Nilai-nilai ini menunjukkan bahwa rata-rata kesalahan prediksi atau penyimpangan antara nilai rating aktual dan nilai rating yang diprediksi oleh sistem masih dalam batas yang dapat diterima.

**Kata kunci :** *Sistem Rekomendasi, Firefly, Algorithm, Collaborative Filtering, Pearson Correlation*

## I. Pendahuluan

Karya seni digital seperti film menjadi hiburan yang populer untuk melepas penat dan mengisi waktu luang, terutama selama masa pandemi ketika orang harus tinggal di rumah. Namun, para penikmat film kerap mengalami kesulitan dalam memilih film yang sesuai dengan preferensi mereka, baik dari segi

genre, opini, maupun rating. Adanya perbedaan opini dan rating dari pengguna menimbulkan masalah dalam menentukan film yang tepat untuk ditonton [1]. Ada beberapa pendekatan yang dapat digunakan dalam sistem rekomendasi untuk membantu pengguna menemukan item yang sesuai preferensinya. Pendekatan tersebut antara lain

Collaborative Filtering (CF) yang merekomendasikan item berdasarkan preferensi pengguna lain yang memiliki selera serupa, Content Based Filtering (CBF) yang merekomendasikan item serupa dengan item yang disukai pengguna sebelumnya berdasarkan karakteristik konten, pendekatan demografis yang merekomendasikan berdasarkan karakteristik demografi pengguna, dan sistem rekomendasi hibrida yang mengkombinasikan beberapa pendekatan tersebut [2]. Collaborative Filtering adalah teknik sistem rekomendasi yang memprediksi rekomendasi berdasarkan hubungan antara pengguna, rating item, serta item yang disukai sebelumnya oleh pengguna dengan preferensi serupa. Sementara itu, Content Based Filtering merekomendasikan item yang mirip dengan kecenderungan pengguna, bahkan bagi pengguna yang belum memiliki riwayat preferensi sebelumnya, dengan menggunakan data independen. Selanjutnya, pendekatan demografis memanfaatkan data demografi pengguna seperti pekerjaan, pendidikan, usia, jenis kelamin, dan informasi lainnya untuk memberikan rekomendasi. Terakhir, sistem rekomendasi hibrida menggabungkan beberapa teknik rekomendasi menjadi satu metode agar dapat memberikan rekomendasi yang lebih akurat dan komprehensif [3].

Dalam teknik User-Based Collaborative Filtering (UBCF), tahapan penting adalah mencari nilai kemiripan antar pengguna yang akan digunakan sebagai bobot untuk mengatasi masalah sparsity (kekurangan data). Beberapa metode umum yang digunakan untuk menghitung nilai kemiripan atau jarak antar pengguna antara lain mean-squared difference, korelasi Pearson, cosine similarity, korelasi Spearman, dan adjusted cosine similarity [4].

Penelitian lain menyatakan bahwa metode korelasi Pearson merupakan pilihan tepat untuk menghitung jarak terdekat antar pengguna berdasarkan rating mereka. Penelitian sebelumnya juga menyimpulkan bahwa koefisien korelasi Pearson memberikan peningkatan kualitas dalam menghitung dataset yang besar dibandingkan metode lain

[5]. Sehingga penelitian dilakukan dengan menggunakan pearson guna mencari nilai kemiripan.

Meskipun demikian, Collaborative Filtering (CF) memiliki kelemahan ketika pengguna tidak memberikan rating atau tidak menyukai suatu item, yang akan menyebabkan sparsity atau kekurangan data pengguna dengan kemiripan preferensi. Kondisi ini dapat menyulitkan proses pencarian rekomendasi yang akurat. Untuk mengatasi masalah tersebut, peneliti sebelumnya bernama Sambhav Yadav menyimpulkan bahwa pemberian bobot per item pada matriks rating pengguna dapat membantu menemukan kemiripan antara pengguna dan mengatasi sparsity [1].

Selain itu, penggunaan algoritma genetika yang merupakan algoritma optimasi pencarian yang efektif dalam ruang pencarian yang besar, dapat dimanfaatkan untuk membantu menemukan kemiripan antar pengguna. Algoritma genetika bekerja dengan cara mencari solusi optimal dari suatu permasalahan melalui proses evolusi biologi seperti seleksi alam, perkawinan silang, dan mutasi [6].

Algoritma Firefly merupakan algoritma optimasi populer yang terinspirasi dari perilaku gerombolan kunang-kunang. Algoritma ini dianggap lebih unggul dalam menyelesaikan permasalahan optimasi dibandingkan dengan algoritma genetika. Dalam penelitian ini, algoritma Firefly digunakan untuk menentukan pengguna-pengguna yang memiliki nilai kemiripan preferensi yang tinggi [7].

Penelitian ini mengkombinasikan metode korelasi Pearson dan algoritma Firefly dengan pendekatan User-Based Collaborative Filtering untuk memberikan rekomendasi film. Dengan mengkombinasikan algoritma Firefly yang kuat dalam optimasi dan metode korelasi Pearson yang tepat dalam menghitung kemiripan berdasarkan rating, diharapkan dapat menghasilkan rekomendasi film yang lebih akurat dan sesuai dengan preferensi pengguna [8].

## II. Teori Dasar

Algoritma kunang-kunang (firefly algorithm) merupakan salah satu jenis algoritma kumpulan (swarm) yang masih menjadi bagian dari algoritma metaheuristik berbasis biologi. Algoritma kunang kunang ditemukan oleh Xin She Yang pada tahun 2008 yang mana algoritma ini terinspirasi dari perilaku serangga kunang-kunang [9] dalam berkomunikasi dan membentuk suatu kelompok atau kumpulan di alam liar. Dari perilaku tersebut di rumuskanlah suatu algoritma yang dapat digunakan dalam menyelesaikan banyak masalah salah satunya dalam sistem rekomendasi mengenai suatu hal yang mana dalam hal ini adalah merekomendasikan film.

Algoritma Kunang kunang terinspirasi dari perilaku kunang kunang itu sendiri di alam liar. Kunang kunang di alam liar berkomunikasi dengan cara mengeluarkan dan mengedipkan cahaya yang disebut bioluminesensi [10] dimana cahaya ini berasal dari zat yang bernama luciferin dimana jika zat ini bereaksi dengan oksigen akan menghasilkan cahaya [11]. Kunang-kunang mengeluarkan cahaya ini untuk berbagai tujuan, termasuk saling mengenali, memberi tanda kawin, dan sebagai mekanisme pertahanan diri dari pemangsa.

Mekanisme pencahayaan inilah yang menjadi dasar terinspirasi algoritma kunang-kunang, dimana dalam algoritma ini data-data yang ada diibaratkan sebagai kunang-kunang di alam. Data-data ini kemudian akan dihitung nilai fitness nya untuk menentukan data mana yang menjadi kunang-kunang dengan tingkat pencahayaan yang paling tinggi sehingga kunang-kunang (dalam hal ini data-data yang digunakan) lain akan mengikuti kunang-kunang dengan pencahayaan yang paling terang.

Dalam algoritma kunang kunang terdapat beberapa variabel yang mempengaruhi serta berperan penting selama proses perhitungan yaitu intensitas cahaya dan jarak. Intensitas cahaya merupakan seberapa terang cahaya yang dipancarkan oleh kunang kunang sedangkan maksud jarak disini adalah jarak antara satu kunang kunang dengan kunang kunang lain.

Intensitas cahaya dan jarak memiliki hubungan berbanding terbalik yang berarti intensitas cahaya akan berkurang jika jarak antar kunang kunang meningkat. Dari hubungan tersebut dapat dirumuskan sebagai berikut :

$$I = \frac{1}{r^2} \quad (1)$$

Keterangan :

I : Intensitas cahaya

r : jarak antar kunang-kunang

Dalam algoritma kunang-kunang terdapat sebuah istilah yang dinamakan ketertarikan (Attractiveness) dimana hal ini menunjukkan daya tarik kunang kunang terhadap kunang kunang lainnya. Daya tarik kunang kunang sebanding dengan intensitas cahaya yang di pancarkannya, daya tarik dapat dirumuskan dengan persamaan berikut.

$$\beta(r) = \beta_0 e^{-\gamma r^2} \quad (2)$$

Keterangan :

$\beta_0$  : Daya tarik kunang kunang saat jarak 0

$\gamma$  : Koefisien penyerapan cahaya

r : Jarak

Adapun gerak firefly i yang tertarik pada firefly j yang memiliki daya tarik lebih besar dapat didefinisikan sebagai berikut :

$$x_i = x_i + \beta_0 e^{-\gamma r^2} (x_j - x_i) + \alpha (rand - \frac{1}{2}) \quad (3)$$

Keterangan :

$x_i$  : Posisi kunang-kunang

$\beta_0 e^{-\gamma r^2}$  : Daya tarik kunang kunang

$\alpha$  : Tingkat pengacakan

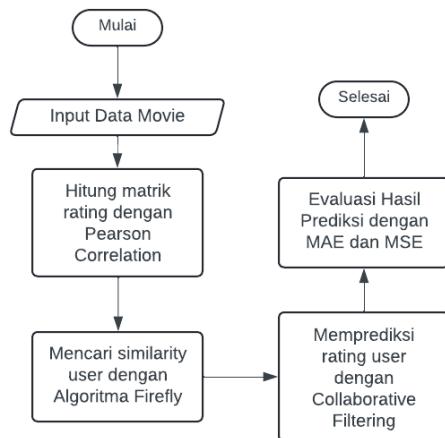
rand : Nomor acak [0, 1]

## III. Metode

Penelitian ini dimulai dengan menginput data film. Langkah selanjutnya adalah menghitung matriks rating menggunakan *Pearson Correlation* untuk mengetahui hubungan antar rating. Setelah itu, mencari

*similarity* pengguna dengan Algoritma Firefly guna menemukan pengguna yang memiliki kesamaan preferensi. Dengan memanfaatkan *similarity* tersebut, prediksi rating pengguna dilakukan menggunakan metode *Collaborative Filtering*. Hasil prediksi kemudian dievaluasi menggunakan metrik *Mean Absolute Error* (MAE) dan *Mean Squared Error* (MSE) untuk mengukur akurasi prediksi. Proses penelitian ini berakhir setelah evaluasi hasil prediksi selesai dilakukan. Diagram alir penelitian ditunjukkan pada Gambar 1.

Penelitian ini menerapkan Algoritma Firefly dalam sistem rekomendasi film untuk mengoptimalkan pencarian *similarity* pengguna, dan meningkatkan akurasi prediksi rating. Dalam proses preprocessing juga data disederhanakan dengan menggabungkan dataset rating dan movie, untuk mempermudah analisis. Evaluasi menggunakan MAE dan MSE menunjukkan hasil yang lebih akurat, membuktikan efektivitas metode ini. Dengan demikian, penelitian ini menawarkan pendekatan baru yang meningkatkan kinerja sistem rekomendasi film.



Gambar 1. Diagram Alir Penelitian

## IV. Hasil dan Pembahasan

### A. Dataset

Dataset yang digunakan untuk mengimplementasikan algoritma firefly

dalam sistem rekomendasi adalah MovieLens 100k yang diperoleh berdasarkan jurnal penelitian terdahulu dan dapat diakses pada link berikut. <https://grouplens.org/datasets/movielens/>.

Dataset ini memiliki data sebanyak 1.700 film, 100.000 rating berdasarkan 1000 user. Pada dataset ini terdapat 4 data utama yang terdiri dari u.data berisikan data rating, u.item berisikan data movie, u.info berisikan data genre movie, dan u.user berisikan data user yang memberikan rating. Optimasi algoritma firefly yang dilakukan berfokus pada dua dataset yakni dataset rating dan movies. Kedua dataset ini digabung menjadi satu yang terdiri dari atribut *user\_id*, *movie\_id*, rating, dan title seperti pada Gambar 2.

	user_id	movie_id	rating	title
0	196	242	3	Kolya (1996)
1	63	242	3	Kolya (1996)
2	226	242	5	Kolya (1996)
3	154	242	3	Kolya (1996)
4	306	242	5	Kolya (1996)
...	...	...	...	...
99995	840	1674	4	Mamma Roma (1962)
99996	655	1640	3	Eighth Day, The (1996)
99997	655	1637	3	Girls Town (1996)
99998	655	1630	3	Silence of the Palace, The (Saimt el Qusur) (1...
99999	655	1641	3	Dadetown (1995)

100000 rows x 4 columns

Gambar 2. Dataset Rating dan Movie

### B. Pearson Correlation Coefficient

Langkah pertama yang dilakukan adalah merepresentasikan data rating kedalam bentuk matriks yang biasa disebut sebagai utility matrix seperti pada Gambar 3. Matriks ini terdiri atas setiap baris yang mewakili user pemberi rating dan kolom yang mewakili item movie id dari setiap movie. Nilai matriks ini merupakan rating yang diberikan oleh user tertentu terhadap suatu movie tertentu. Jika user belum memberikan rating pada suatu movie maka nilai pada matriks akan diisi dengan 0. Matriks rating dapat membantu dalam melihat pola rating user secara keseluruhan

dengan kemiripan antara hasil rating user terhadap movie.

movie_id	1	2	3	4	5	6	7	8	9	10	...
0	5.0	3.0	4.0	3.0	3.0	5.0	4.0	1.0	5.0	3.0	...
1	4.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0	...
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...
4	4.0	3.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...
...	...	...	...	...	...	...	...	...	...	...	...
938	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	5.0	0.0	...
939	0.0	0.0	0.0	2.0	0.0	0.0	4.0	5.0	3.0	0.0	...
940	5.0	0.0	0.0	0.0	0.0	0.0	4.0	0.0	0.0	0.0	...
941	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...
942	0.0	5.0	0.0	0.0	0.0	0.0	0.0	0.0	3.0	0.0	...

943 rows x 1682 columns

Gambar 3. Matriks Rating

Langkah selanjutnya adalah menghitung nilai kemiripan pada rating melalui matriks korelasi berdasarkan similarity seperti pada Gambar 4. Metode korelasi pearson mengukur kekuatan hubungan linier antara dua variabel. Pada konteks ini, korelasi pearson digunakan untuk menghitung kemiripan antara rating yang diberikan oleh user terhadap item movie yang berbeda.

Nilai korelasi pearson yang dihasilkan berada pada rentang -1 hingga 1. Nilai yang positif menunjukkan korelasi positif dan berarti jika seorang user memberikan rating yang tinggi pada satu movie, maka besar kemungkinan user tersebut memberikan rating yang tinggi pada item movie lain yang memiliki korelasi positif. Sebaliknya, jika nilai menunjukkan negatif, maka korelasi negatif yang berarti jika seorang user memberikan rating tinggi pada suatu item movie maka besar kemungkinan user akan memberikan rating rendah pada item movie lain yang memiliki korelasi negatif. Hal ini dapat mengetahui kemiripan antar item movie sehingga sistem dapat merekomendasikan item movie yang mirip dan disukai oleh user tersebut.

	0	1	2	3	4	5	6	7	8	9	...
0	0.000000	0.893678	1.016424	0.978284	6.974079e-01	0.654024	0.679983	0.723792	0.961188	0.711509	...
1	0.893678	0.000000	0.917320	0.839677	9.797822e-01	0.602156	0.977114	0.927228	0.896284	0.893139	...
2	1.016424	0.917320	0.000000	0.668326	1.028322e+00	0.982327	1.013384	0.944815	0.956495	0.987920	...
3	0.978284	0.839677	0.668326	0.000000	1.002426e+00	0.969794	0.958944	0.828884	0.910628	0.975882	...
4	6.974079e-01	9.797822e-01	1.028322e+00	1.002426e+00	0.000000	0.846591	0.720323	0.790720	0.974504	0.882834	...
...	...	...	...	...	...	...	...	...	...	...	...
938	0.939825	0.786906	1.001145	0.989110	9.757076e-01	0.940513	0.967409	0.931730	0.978331	0.981843	...
939	0.752517	0.809152	0.872481	0.825096	8.175337e-01	0.704051	0.748012	0.786592	0.903114	0.712417	...
940	0.884496	0.855623	0.915408	0.859189	8.874286e-01	0.886142	0.991832	0.870904	0.867600	0.942816	...
941	0.891016	0.861708	0.897975	0.850425	9.033972e-01	0.733655	0.789610	0.857168	0.929305	0.845705	...
942	0.676769	0.945765	1.023601	0.974633	7.510067e-01	0.805075	0.698003	0.737187	0.955273	0.861812	...

943 rows x 943 columns

Gambar 4. Matriks Korelasi Pearson

### C. Algoritma Firefly

Kemudian dilakukan pencarian *best firefly* seperti pada Gambar 5. *Best firefly* menunjukkan daftar solusi terbaik yang dihasilkan oleh algoritma firefly dengan 943 populasi dan gen. Setiap angka dalam daftar *best firefly* tersebut merepresentasikan identifikasi unik atau nilai dari solusi terbaik.

**Best Firefly: [195, 630, 943,**

Gambar 5. Output *Best Firefly*

Setelah itu membuat data frame dari daftar *best firefly* seperti pada Gambar 6. Diperoleh data frame dengan 2 kolom, yaitu “user\_id” dan “weight”. “User\_id” merupakan daftar dari *best firefly* terbaik yang ditemukan oleh algoritma firefly. “Weight” merupakan intensitas cahaya dari masing-masing *best firefly* yang diurutkan secara menurun. Dari dataframe juga dapat diketahui total data sebanyak 943 baris dengan 2 kolom.

	user_id	weight
0	195.0	0.585707
1	630.0	0.544848
2	943.0	0.507883
3	656.0	0.355367
4	117.0	0.301915
...	...	...
938	414.0	0.001230
939	576.0	0.001228
940	260.0	0.001228
941	311.0	0.001225
942	NaN	0.001225

943 rows x 2 columns

Gambar 6. Output Dataframe dari Best Firefly

Selanjutnya, dilakukan penghapusan pada data yang memiliki nilai null. Diperoleh data frame dengan 942 baris dan 2 kolom seperti pada Gambar 7. Artinya, terdapat 1 data yang memiliki nilai null dan sudah dihapus, sehingga dataframe hanya akan berisi baris yang valid dengan nilai “user\_id” dan “weight” yang lengkap.

	user_id	weight
0	195.0	0.585707
1	630.0	0.544848
2	943.0	0.507883
3	656.0	0.355367
4	117.0	0.301915
...	...	...
937	482.0	0.001230
938	414.0	0.001230
939	576.0	0.001228
940	260.0	0.001228
941	311.0	0.001225

942 rows x 2 columns

Gambar 7. Output Dataframe Setelah Dihapus Data NaN

Menghitung statistik deskriptif dari data frame sebelumnya dengan menggunakan fungsi `describe()`. Kemudian akan menampilkan jumlah baris data tidak null untuk setiap kolom (`count`), nilai rata-rata (`mean`), standar deviasi (`std`), nilai minimal (`min`), maksimal (`max`), kuartil pertama (25%), kuartil kedua (50%), dan kuartil ketiga (75%) dari masing-masing kolom “user\_id” dan “weight” seperti pada Gambar 8.

	user_id	weight
count	942.000000	942.000000
mean	472.500000	0.009336
std	272.076276	0.032248
min	2.000000	0.001225
25%	237.250000	0.001613
50%	472.500000	0.002379
75%	707.750000	0.005376
max	943.000000	0.566001

Gambar 8. Output Statistik Deskriptif

#### D. User Based Collaborative Filtering

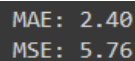
Dengan menggunakan fungsi “`predict_rating`”, prediksi rating untuk pengguna 566 pada item 1 adalah sebesar 0.60. Hal ini menunjukkan bahwa berdasarkan kesamaan antara pengguna 566 dengan pengguna lain yang telah memberikan rating pada item tersebut, rating yang diprediksi adalah sekitar 0.60.

Prediksi rating untuk pengguna 566 pada item 1: 0.60

Gambar 9. Output Prediksi *Rating User Based Collaborative Filtering*

#### E. Pengujian

Selanjutnya, dilakukan pengujian MAE dan MSE. Diperoleh nilai MAE sebesar 2.40, artinya rata-rata dari selisih absolut antara prediksi dan nilai sebenarnya adalah 2.40. Kemudian, diperoleh nilai MSE sebesar 5.76, artinya rata-rata dari kuadrat selisih antara prediksi dan nilai sebenarnya adalah 5.76.



MAE : 2.40  
MSE : 5.76

Gambar 10. Output Evaluasi Prediksi Rating dengan MAE dan MSE

## V. Kesimpulan

Penelitian ini menunjukkan bahwa penggunaan Algoritma Firefly dalam sistem rekomendasi film dapat meningkatkan akurasi prediksi rating. Implementasi dimulai dengan pemrosesan dataset MovieLens 100k, menghasilkan matriks rating yang memudahkan analisis pola rating pengguna. Penggunaan *Pearson Correlation* dalam menghitung kesamaan pengguna memungkinkan identifikasi hubungan linier yang kuat antara rating film. Hasil ini mendukung langkah selanjutnya yaitu pencarian similarity pengguna menggunakan Algoritma Firefly, yang berhasil menghasilkan daftar best firefly dengan solusi optimal.


Setelah membersihkan data dari nilai null, data frame yang dihasilkan dianalisis secara deskriptif, menunjukkan distribusi data yang baik tanpa nilai null yang signifikan. Prediksi rating dengan metode *User-Based Collaborative Filtering* menghasilkan nilai prediksi yang realistis, contohnya rating 0.60 untuk pengguna tertentu. Evaluasi prediksi menunjukkan nilai MAE sebesar 2.40 dan MSE sebesar 5.76, menunjukkan bahwa rata-rata kesalahan prediksi masih dalam batas yang dapat diterima. Kesimpulannya, metode yang digunakan efektif dalam meningkatkan akurasi prediksi rating film, menunjukkan potensi besar dalam aplikasi sistem rekomendasi.

## REFERENSI

- [1] Al-Bakhari, & Hashim. (2018, Juni). Reducing Data Sparsity in Recommender Systems. *Journal of Al-Nahrain University*, 2, 38-147.
- [2] Arianti, Via, & Purbasari. (2020, Juli). Implementasi Algoritma Firefly Dalam Menyelesaikan Pengoptimalan Produksi Sepatu (Studi Kasus : Home industry “PAK KICU Shoes” Sidoarjo). *Jurnal Informatika dan Sistem Informasi (JIFoSI)*, 1.
- [3] Fayyaz, Ebrahimian, Nawara, Ibrahim, & Kashef. (2020). Recommendation Systems: Algorithms, Challenges, Metrics, and Business Opportunities. *Applied Science*.
- [4] Hays. (2017, Juni). Implementasi Firefly Algorithm-Tabu Search Untuk Penyelesaian Traveling Salesman Problem. *JOIN*, 2.
- [5] Jaja, Susanto, & Sasongko. (2020). Penerapan Metode Item-Based Collaborative Filtering Untuk Sistem Rekomendasi Data MovieLens. d’Cartesian. *Jurnal Matematika dan Aplikasi*, 9, 1-6.
- [6] Jepriana, & Wardoyo. (2018). Algoritma Genetika untuk Mengurangi Galat Prediksi Metode Item-based Collaborative Filtering. *BIMIPA*, 2, 165-174.

- [7] Tommy, Novianto, & Japriadi. (2020, Desember). Sistem Rekomendasi Hybrid Untuk Pemesanan Hidangan Berdasarkan Karakteristik Dan Rating Hidangan. *Journal Of Applied Informatics And Computing(JAIC)*, 4, 137-145.
- [8] Yadav, Vikes, Shreyam, & Nagpal. (2018). An Improved Collaborative Filtering Based Recommender System Using Bat Algorithm. *Procedia Computer Science*, 1795-1803
- [9] N. D. Ismail Dif, “Firefly Algorithm Optimization-Based LQR Controller for 1/4 Vehicle Active Suspension System: Design and Performance Evaluation,” *The Journal of Engineering and Exact Sciences*, vol. 09, no. 05, pp. 1-12, 2023
- [10] F. V. Y. S. Y. T. M. L. Zemin Zhang, “Bio-inspired optical structures for enhancing luminescence,” *Exploration*, no. 3, pp. 1-17, 2022
- [11] White, E.H., Steinmetz, M.G., Miano, J.D., Wildes, P.D. and Morland, R., Chemi-and bioluminescence of firefly luciferin. *Journal of the American Chemical Society*, 102(9), pp.3199-3208.

*Lampiran 1. Kode pemrograman*

 Kelompok 8\_SI Tubes.ipynb

*Lampiran 2. Dataset*

<https://grouplens.org/datasets/movielens/>

## LAMPIRAN